



INTRODUÇÃO À INTELIGÊNCIA COMPUTACIONAL

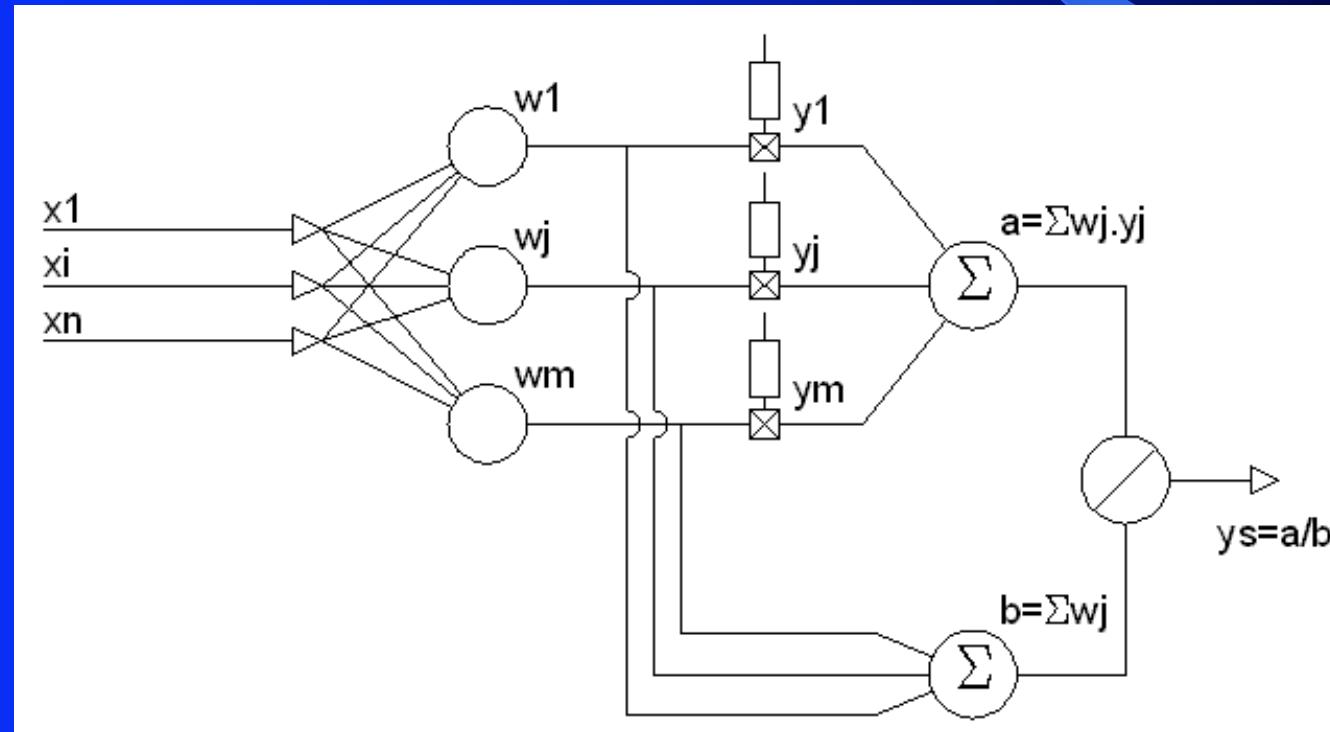
SISTEMAS NEBULOSOS ADAPTATIVOS: NEO-FUZZY-NEURON

Prof. Walmir Matos Caminhas - DELT/UFMG

PROPOSTA

- YAMAKAWA: NEO-FUZZY-NEURON;
- CAMINHAS: TREINAMENTO ON-LINE.

Estrutura Neurofuzzy



Regras implementadas

Se $(x_1 \in A_{1j}) \text{ e } (x_2 \in A_{2j}) \dots \text{e } (x_i \in A_{ij}) \dots \text{e } (x_n \in A_{nj})$

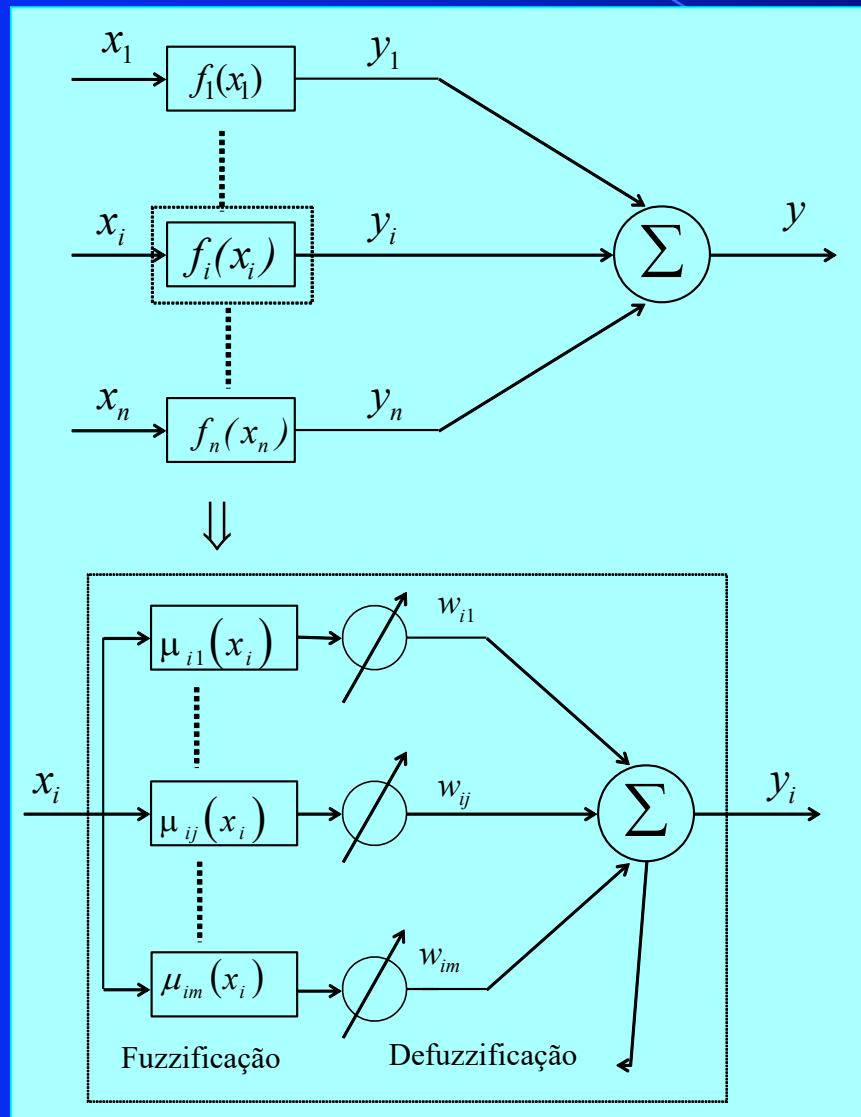
Então $y = P_{1j}x_1 + P_{2j}x_1 + \dots + P_{ij}x_1 + P_{nj}x_n + q_j$

$$y_j = \sum_{i=1}^n P_{ij} x_i + q_j$$

$$w_j = \prod_{i=1}^n \mu_{Aij}(x_i)$$

$$w_j = \mu_{A1j}(x_1) \cdot \mu_{A2j}(x_2) \cdot \dots \cdot \mu_{Aij}(x_j) \cdot \mu_{Anj}(x_n)$$

ESTRUTURA DO NFN



ESTRURA DO NFN

Se x_i é A_{il} Então y_i é w_{il}

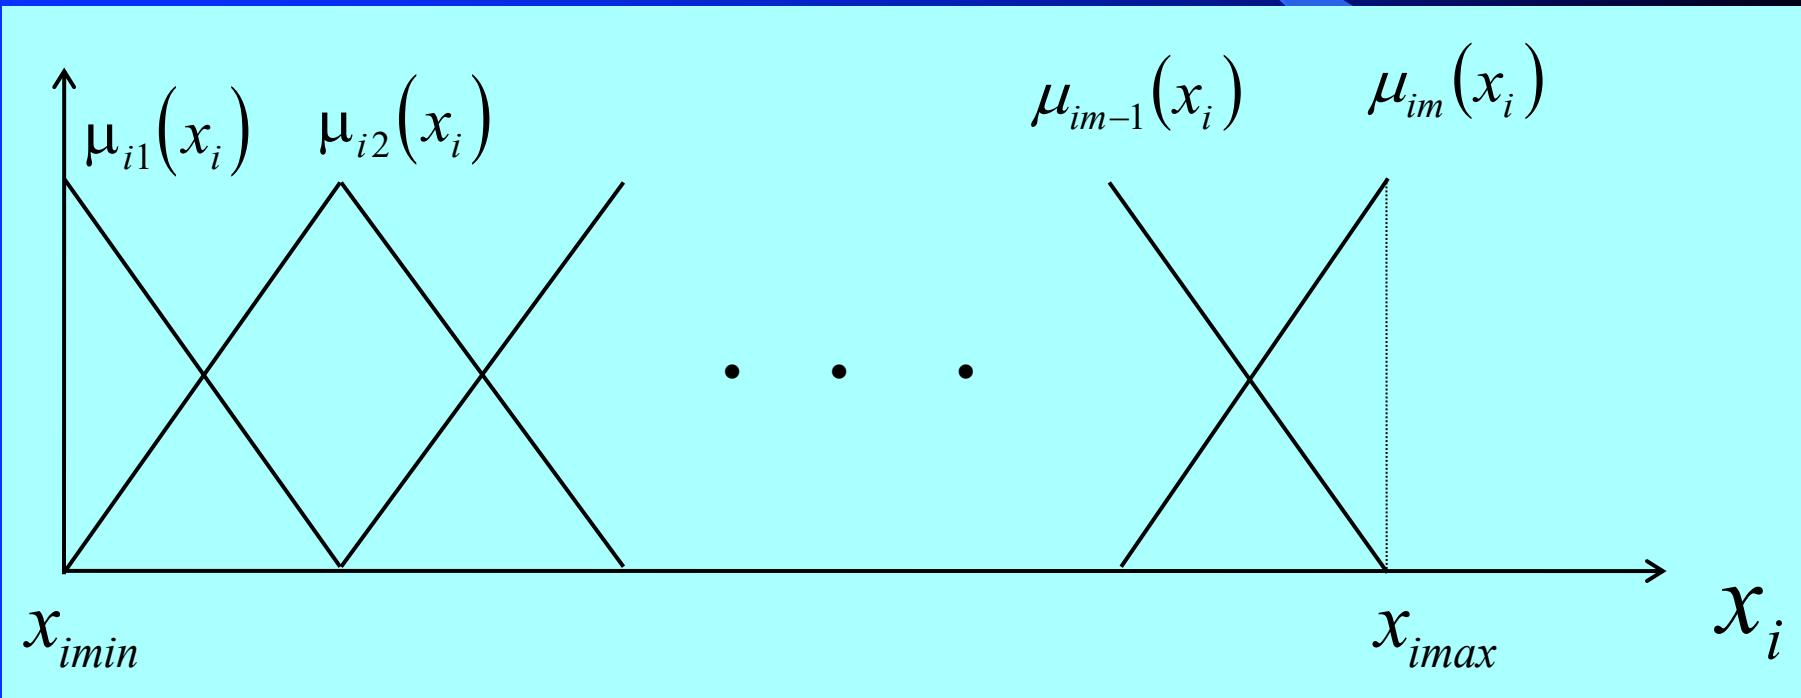
⋮

Se x_i é A_{im} Então y_i é w_{im}

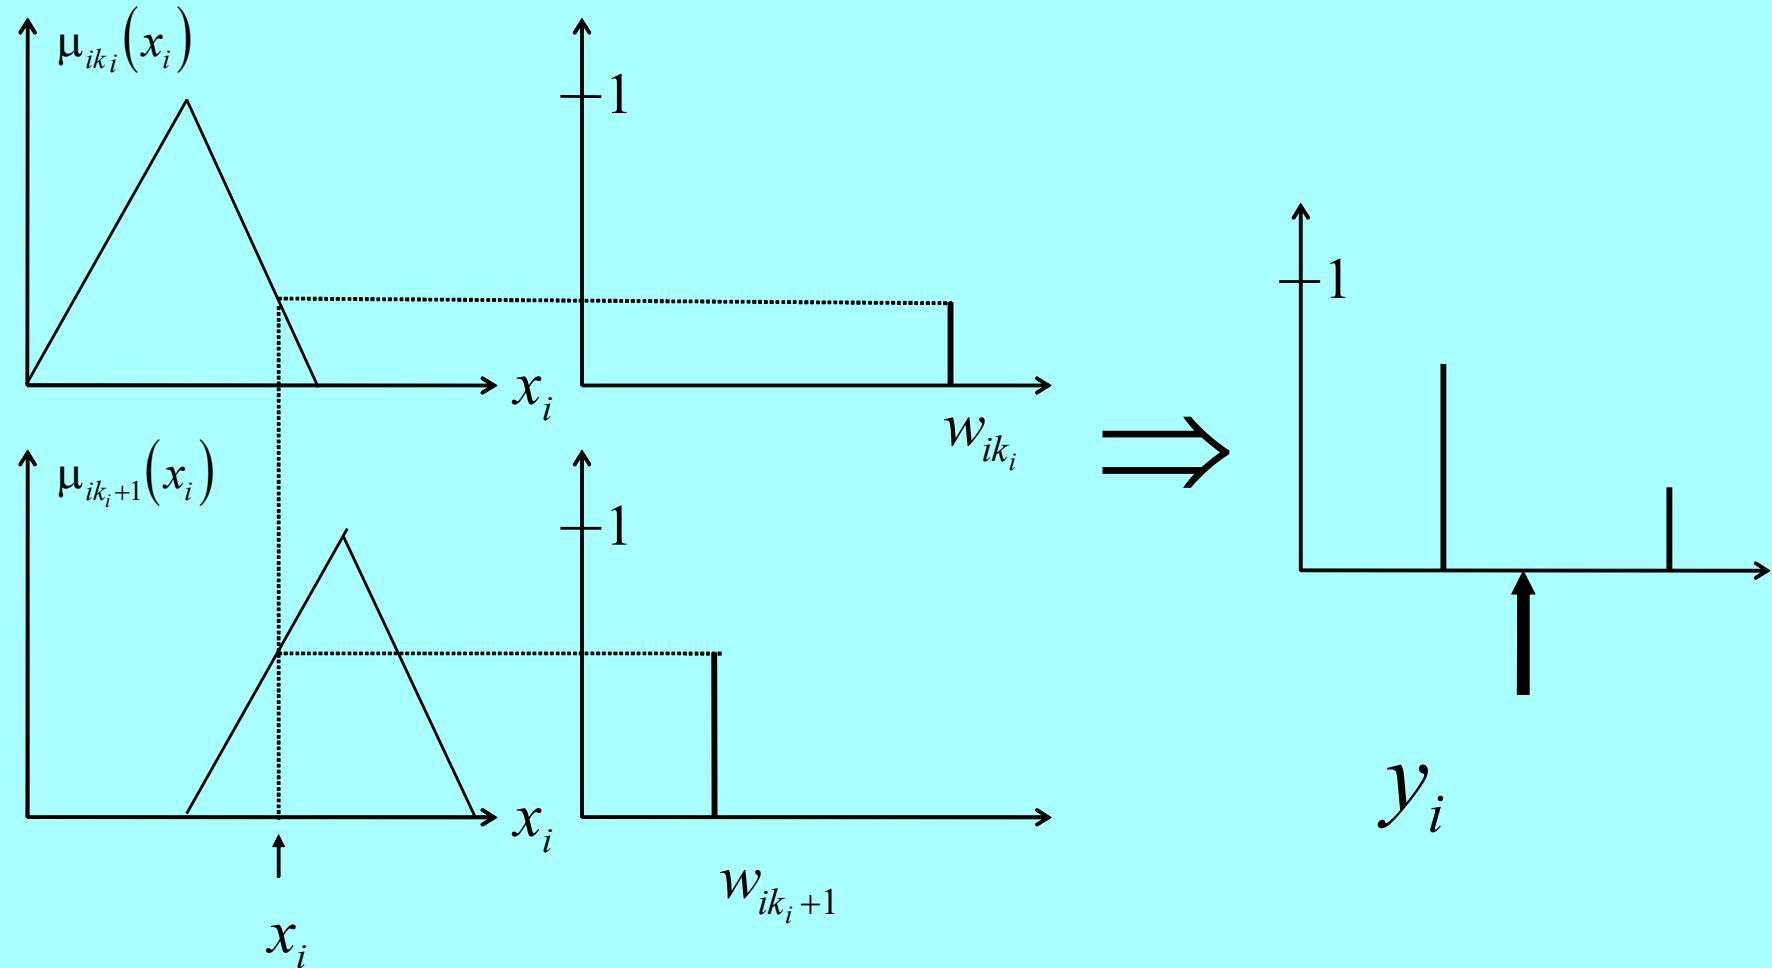
ESTRUTURA DO NFN

$$y = \sum_{i=1}^n y_i(x_i) = \sum_{i=1}^n f_i(x_i)$$

ESTRUTURA



MECANISMO DE INFERÊNCIA



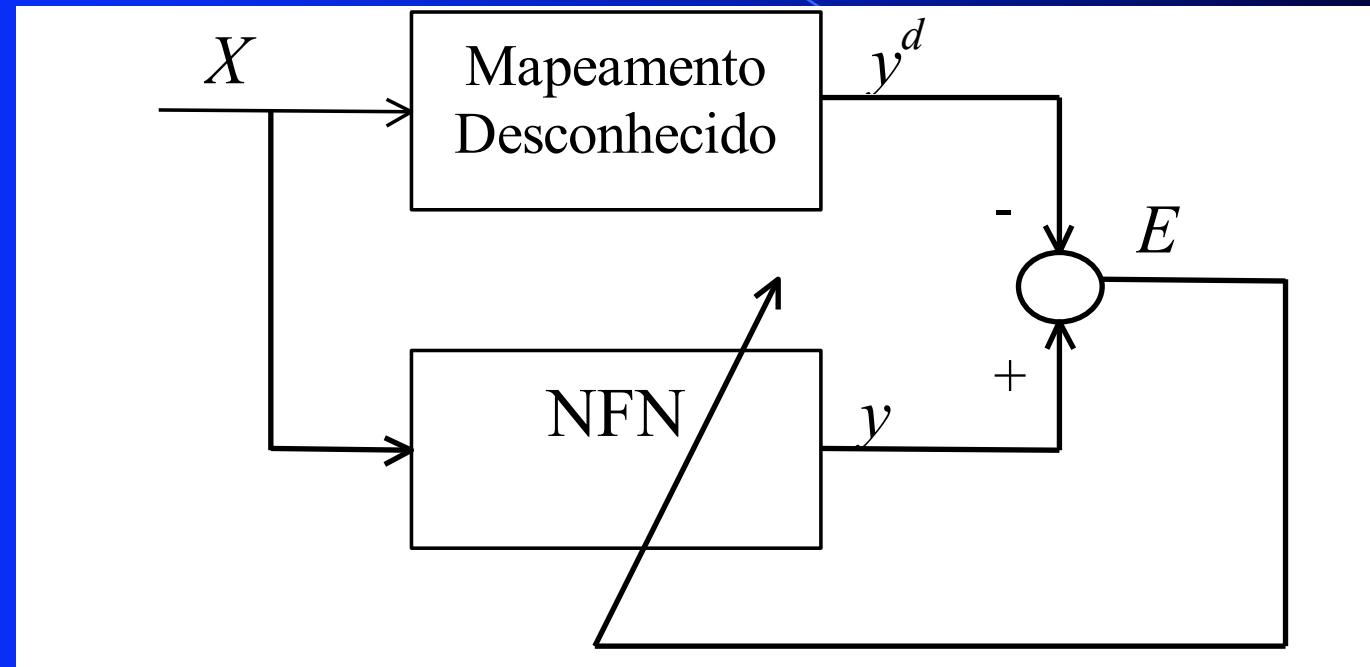
COMPUTAÇÃO DA SAÍDA

$$f_i(x_i) = \frac{\sum_{j=1}^m \mu_{ij}(x_i) \cdot w_{ij}}{\sum_{j=1}^m \mu_{ij}(x_i)}$$
$$= \frac{\mu_{ik_i}(x_i) \cdot w_{ik_i} + \mu_{ik_i+1}(x_i) \cdot w_{ik_i+1}}{\mu_{ik_i}(x_i) + \mu_{ik_i+1}(x_i)}$$

COMPUTAÇÃO DA SAÍDA

$$f_i(x_i) = \mu_{ik_i}(x_i) \cdot w_{ik_i} + \mu_{ik_i+1}(x_i) \cdot w_{ik_i+1}$$

APRENDIZADO DO NFN



$$E_t = \frac{1}{2} (y_t - y_t^d)^2 = E_t(w_{ij})$$

APRENDIZADO DO NFN

$$\min E_t = E_t(w_{ij})$$

$$w_{ij} \in \Re$$

$$\forall i = 1, \dots, n; j = 1, \dots, m$$

APRENDIZADO DO NFN

$$\min \quad E_t = E_t(w_{ij}) = E_t(\tilde{w})$$

$$w_{ij} \in \Re$$

$$\forall i = 1, \dots, n; j = k_i, (k_i + 1)$$

$$\tilde{w} = [w_{1k_1} \ w_{1(k_1+1)} \dots w_{ik_i} \ w_{i(k_i+1)} \dots w_{nk_n} \ w_{n(k_n+1)}]$$

APRENDIZADO DO NFN

$$\nabla E_t(\tilde{w}) = (y_t - y_t^d)$$

$$\begin{bmatrix} \mu_{1k_1} \\ \mu_{1k_1+1} \\ \vdots \\ \mu_{ik_i} \\ \vdots \\ \mu_{nk_n+1} \end{bmatrix}$$

APRENDIZADO DO NFN

$$H = \begin{bmatrix} \mu_{1k_1}^2 & \mu_{1k_1} \cdot \mu_{1k_1+1} & \cdots & \mu_{1k_1} \cdot \mu_{ik_i} & \cdots & \mu_{1k_1} \cdot \mu_{nk_n+1} \\ \mu_{1k_1} \cdot \mu_{1k_1+1} & \mu_{1k_1+1}^2 & & \cdots & & \mu_{1k_1+1} \cdot \mu_{nk_n+1} \\ \vdots & & \ddots & & & \vdots \\ \mu_{1k_1} \cdot \mu_{ik_i} & & \cdots & \mu_{ik_i}^2 & \cdots & \mu_{ik_i} \cdot \mu_{nk_n+1} \\ \vdots & & \cdots & & \ddots & \vdots \\ \mu_{1k_1} \cdot \mu_{nk_n+1} & \mu_{1k_1+1} \cdot \mu_{nk_n+1} & \cdots & \mu_{ik_i} \cdot \mu_{nk_n+1} & \cdots & \mu_{nk_n+1}^2 \end{bmatrix}$$

$$V^T \cdot H \cdot V = (\nu_1 \cdot \mu_{1k_1} + \nu_2 \cdot \mu_{1k_1+1} + \cdots + \nu_{2n} \cdot \mu_{nk_n+1})^2 \geq 0$$

APRENDIZADO DO NFN

H semi-definida positivo e
E(w) é convexa, portanto,
mínimo global.

APRENDIZADO DO NFN

$$\tilde{h}^j = -\nabla E_t(\tilde{w}^j)$$

$$w_{ik_i}^{j+1} = w_{ik_i}^j - \alpha^j \cdot \frac{\partial E_t(w_{ik_i}^j)}{\partial w_{ik_i}^j}$$

$$w_{ik_i}^{j+1} = w_{ik_i}^j - \alpha^j \cdot (y_t^j - y_t^d) \cdot \mu_{ik_i}(x_{ti})$$

Taxa de Aprendizado Ótima

Teorema:

Dado um padrão e o valor desejado para o mapeamento é possível determinar uma expressão fechada para a taxa de aprendizado α tal que utilizando o método do gradiente, os pesos do NFN que proporcionam erro de aproximação nulo podem ser determinados em um passo.

Prova do Teorema

$$E_t^1 = \frac{1}{2} (y_t^1 - y_t^d)^2 = \frac{1}{2} \cdot (e_t^1)^2 = 0$$

$$e_t^1 = \left(\left(\sum_{i=1}^n w_{ik_i}^1 \cdot \mu_{k_i}(x_i) + w_{ik_i}^1 \cdot \mu_{k_i+1}(x_{ti}) \right) - y_t^d \right)$$

$$w_{ik_i}^1 = w_{ik_i}^0 - \alpha \cdot e_t^0 \cdot \mu_{ik_i}(x_{ti})$$

$$w_{ik_i+1}^1 = w_{ik_i+1}^0 - \alpha \cdot e_t^0 \cdot \mu_{ik_i+1}(x_{ti})$$

APRENDIZADO DO NFN

$$\alpha = \frac{1}{\sum_{i=1}^n \mu_{ik_i} (x_{ti})^2 + \mu_{ik_i+1} (x_{ti})^2}$$

Taxa de aprendizado ótima (Caminhas, 1997)

Identificação de Sistemas Dinâmicos

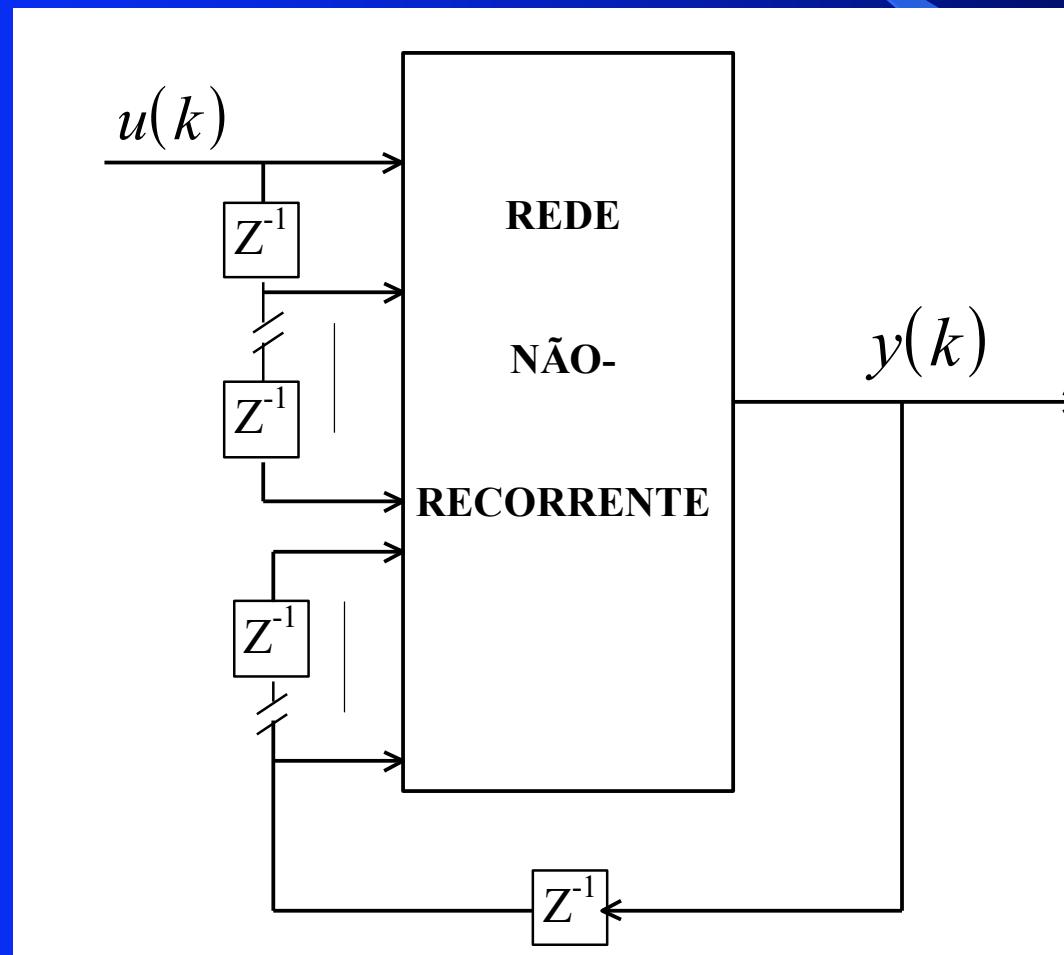
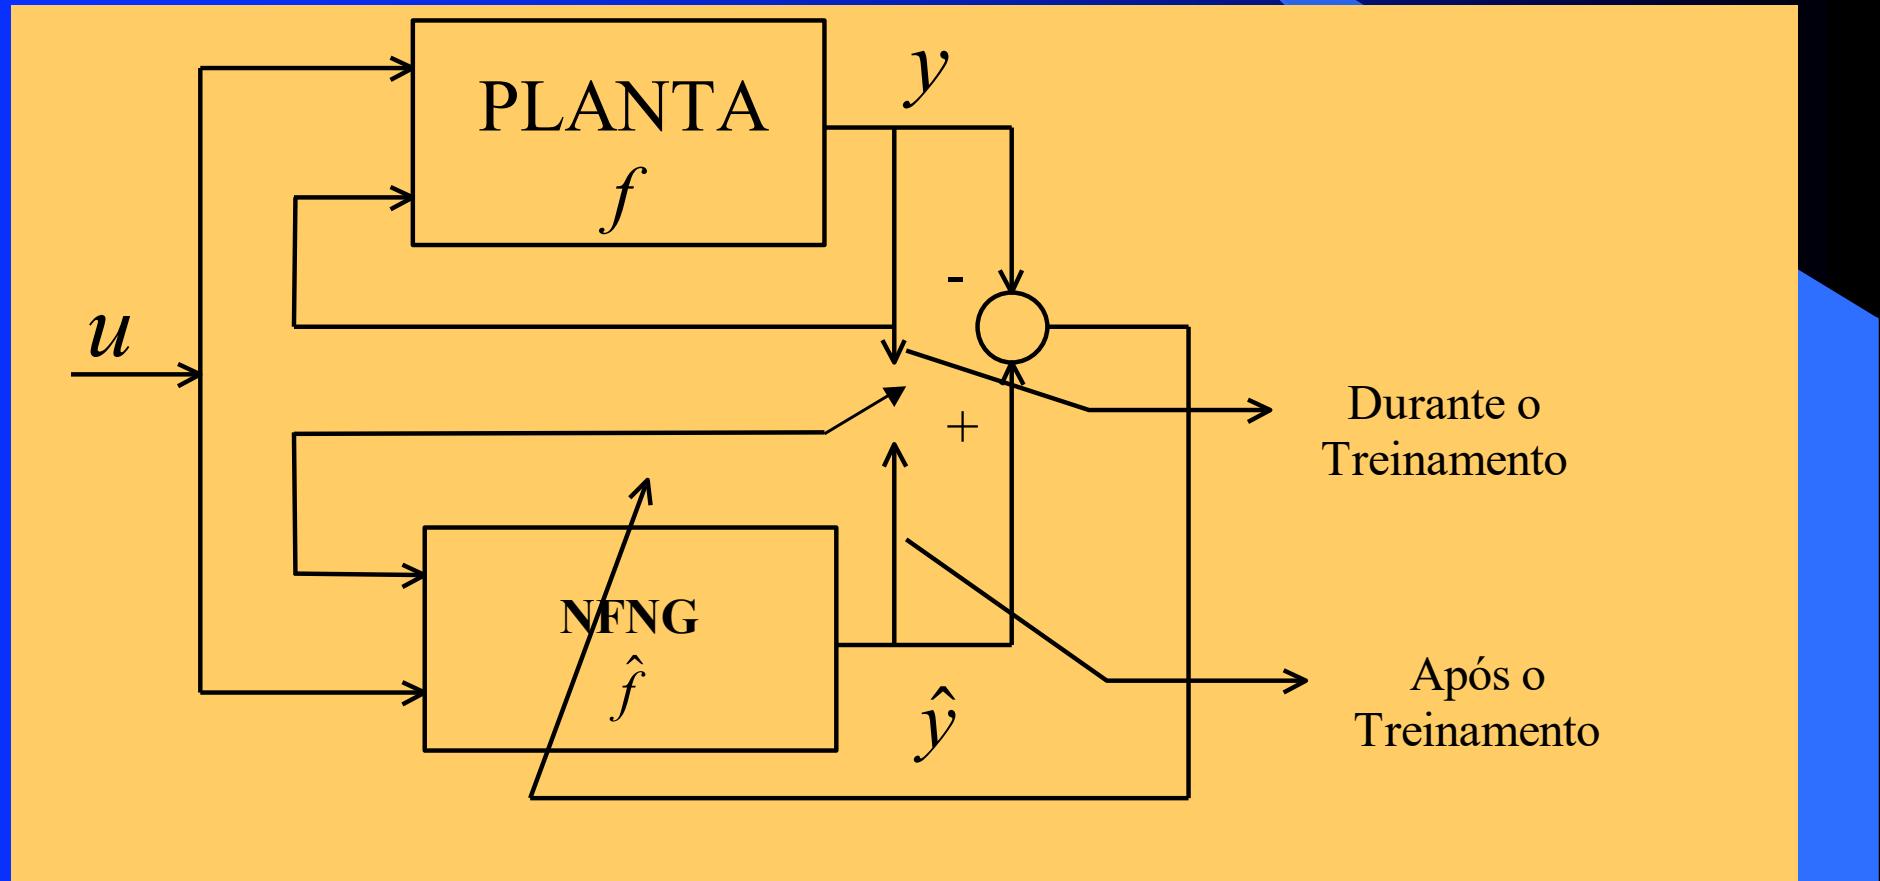


Diagrama da Estratégia de treinamento do NFNG



Exemplo 1

$$y(k+1) = 0.3 \cdot y(k) + 0.5 \cdot y(k-1) + g[u(k)]$$

$$g(u) = 0.6 \sin(\pi u) + 0.3 \sin(3\pi u) + 0.1 \sin(5\pi u)$$

$$\hat{y}(k+1) = 0.3 \cdot \hat{y}(k) + 0.5 \cdot \hat{y}(k-1) + \hat{g}[u(k)]$$

Estrutura do NFN

- Número de entradas: 1
- Número de saídas: 1
- Número de partições nebulosas: 20

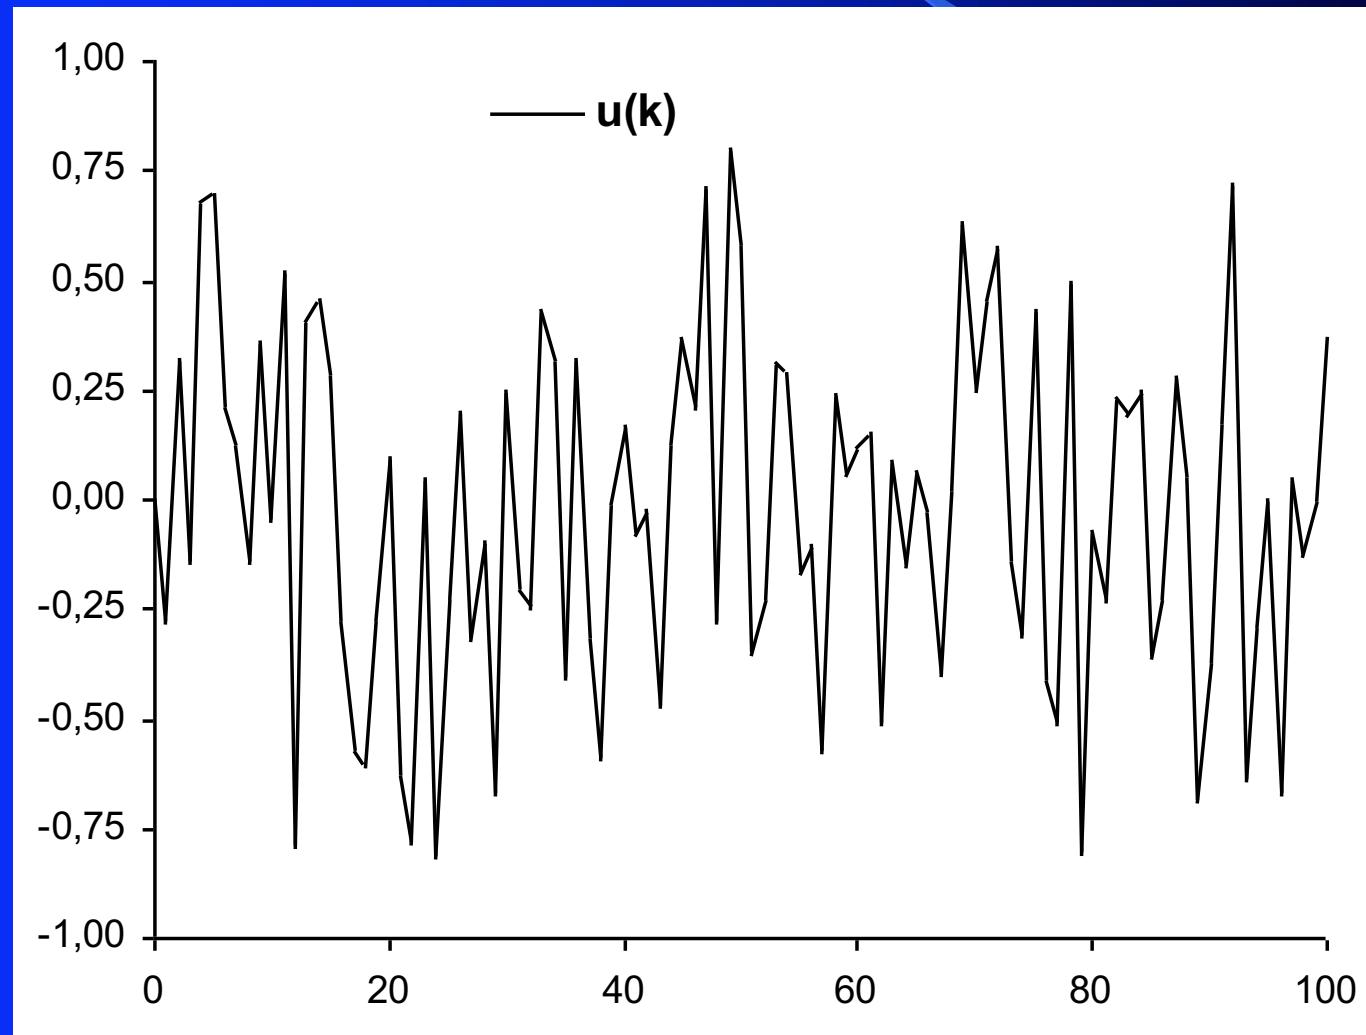
Metodologia de treinamento

- padrões de treinamento: 10.000 com u aleatório no intervalo $[-1, +1]$
- padrões de validação:

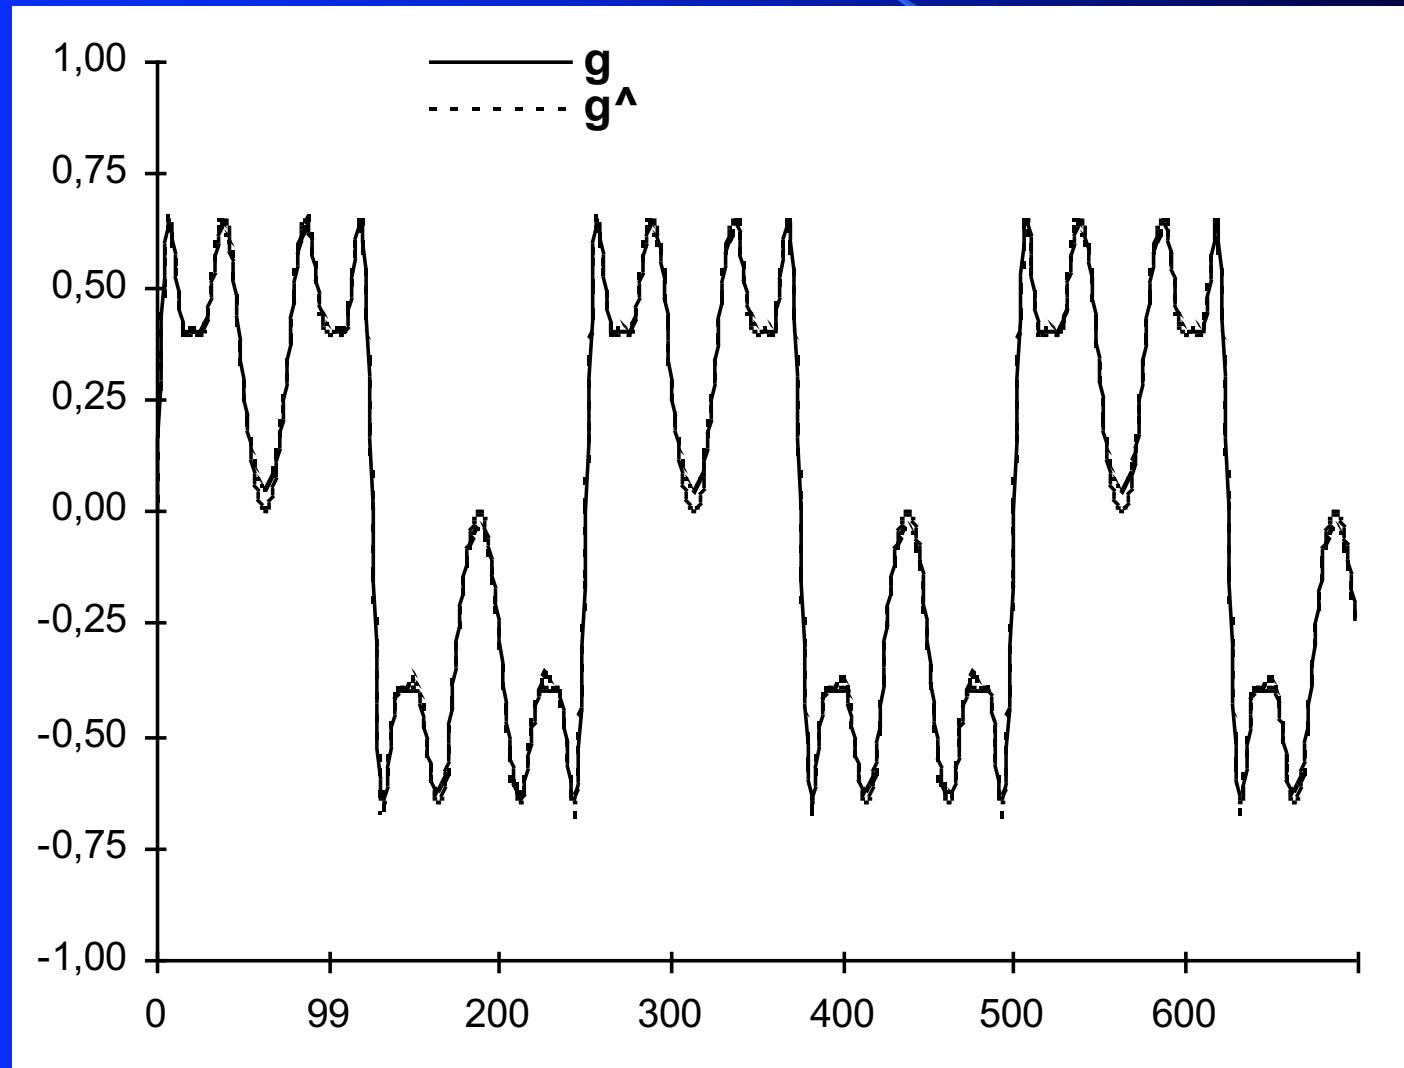
$$u(k) = \text{sen}(2\pi k / 250)$$

$$u(k) = \begin{cases} \text{sen}(2\pi k / 250), & 251 \leq k \leq 500 \\ 0.5 \text{sen}(2\pi k / 25) + 0.5 \text{sen}(2\pi k / 250), & \text{caso contrário} \end{cases}$$

Sinal de u utilizado no treinamento

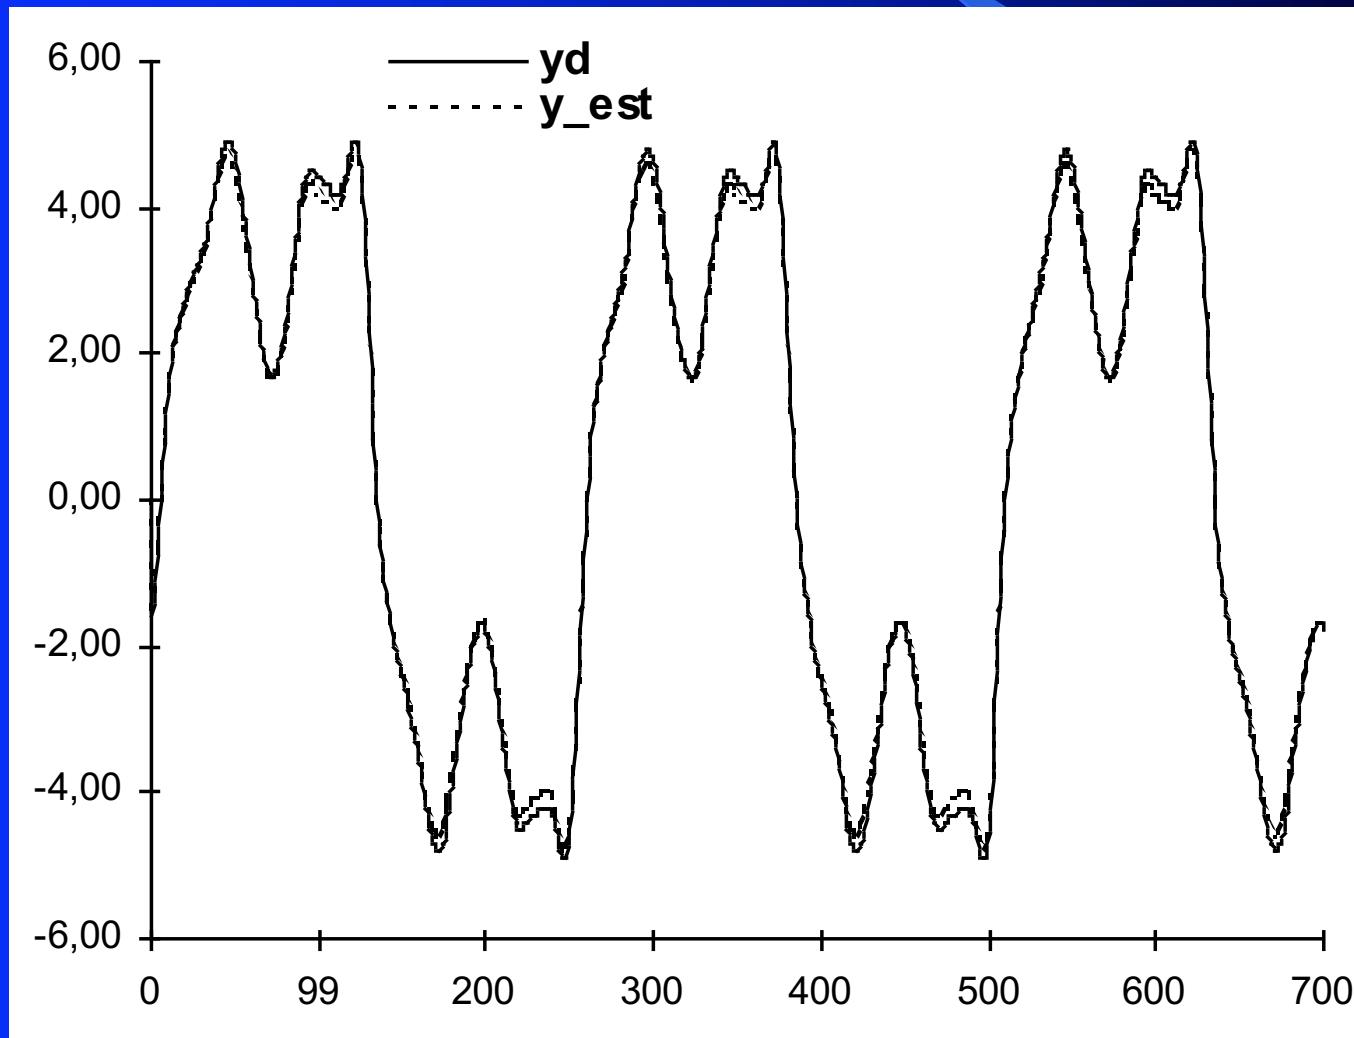


Resultado da identificação

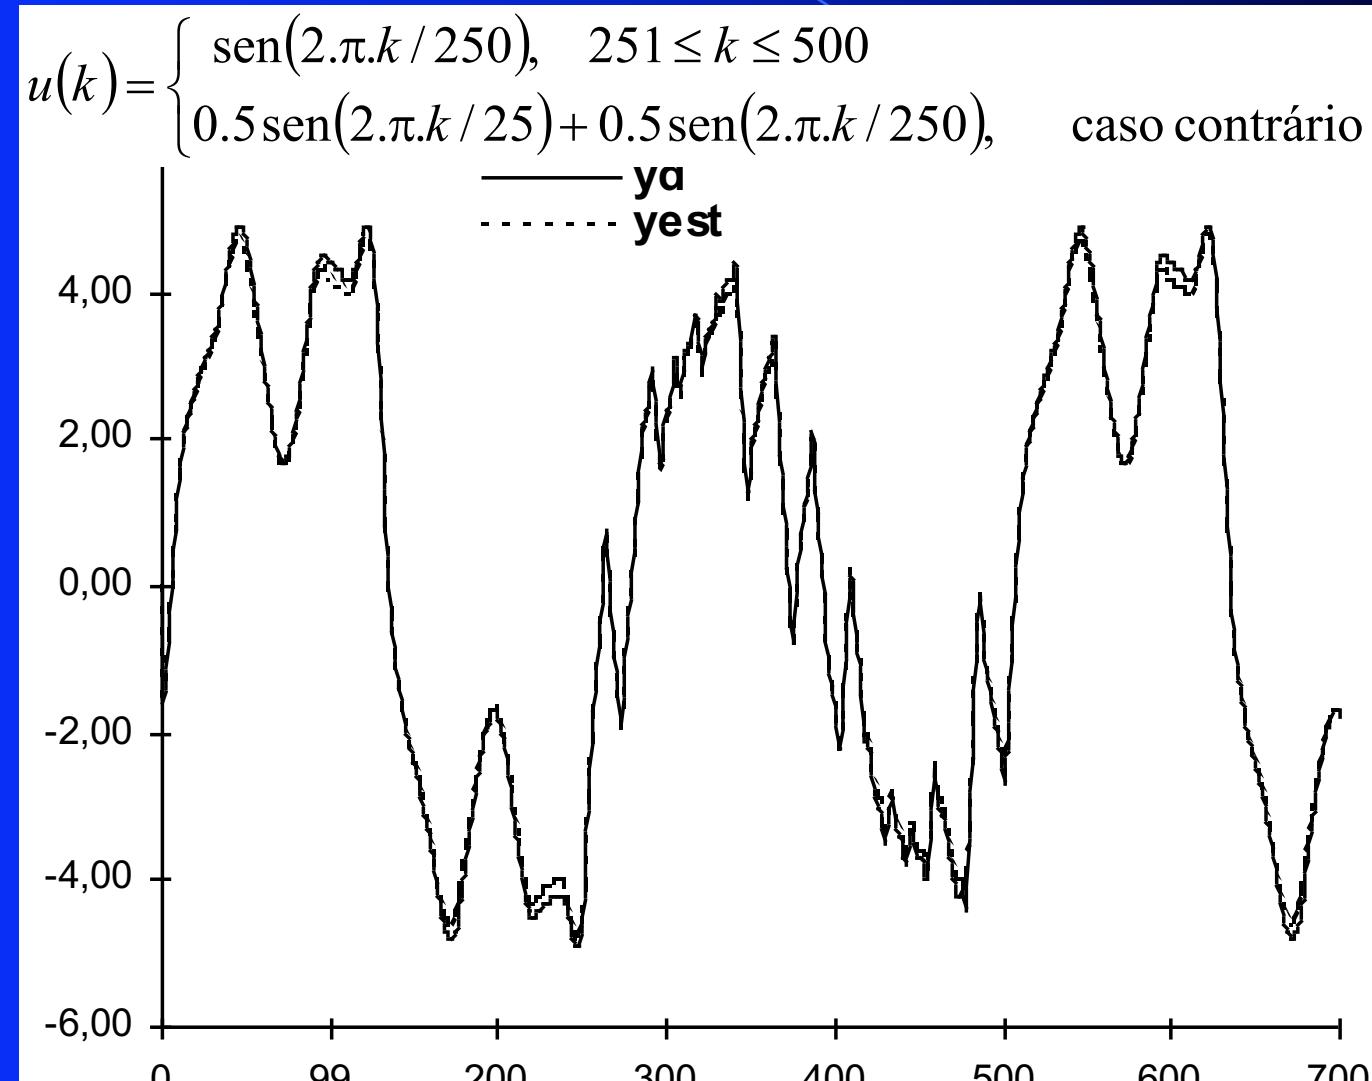


Resultado da identificação

$$u(k) = \sin(2\pi k / 250)$$



Resultado da identificação



RESULTADOS DE IDENTIFICAÇÃO

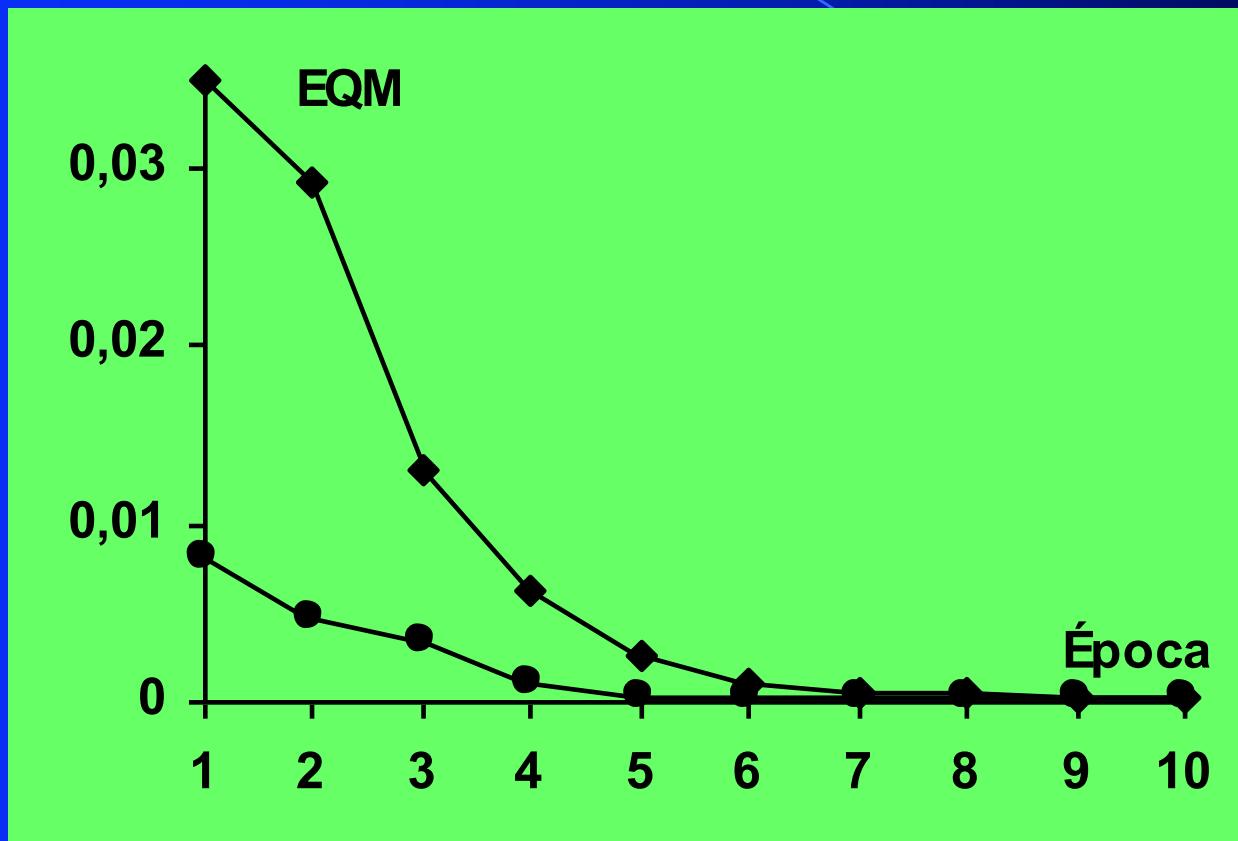
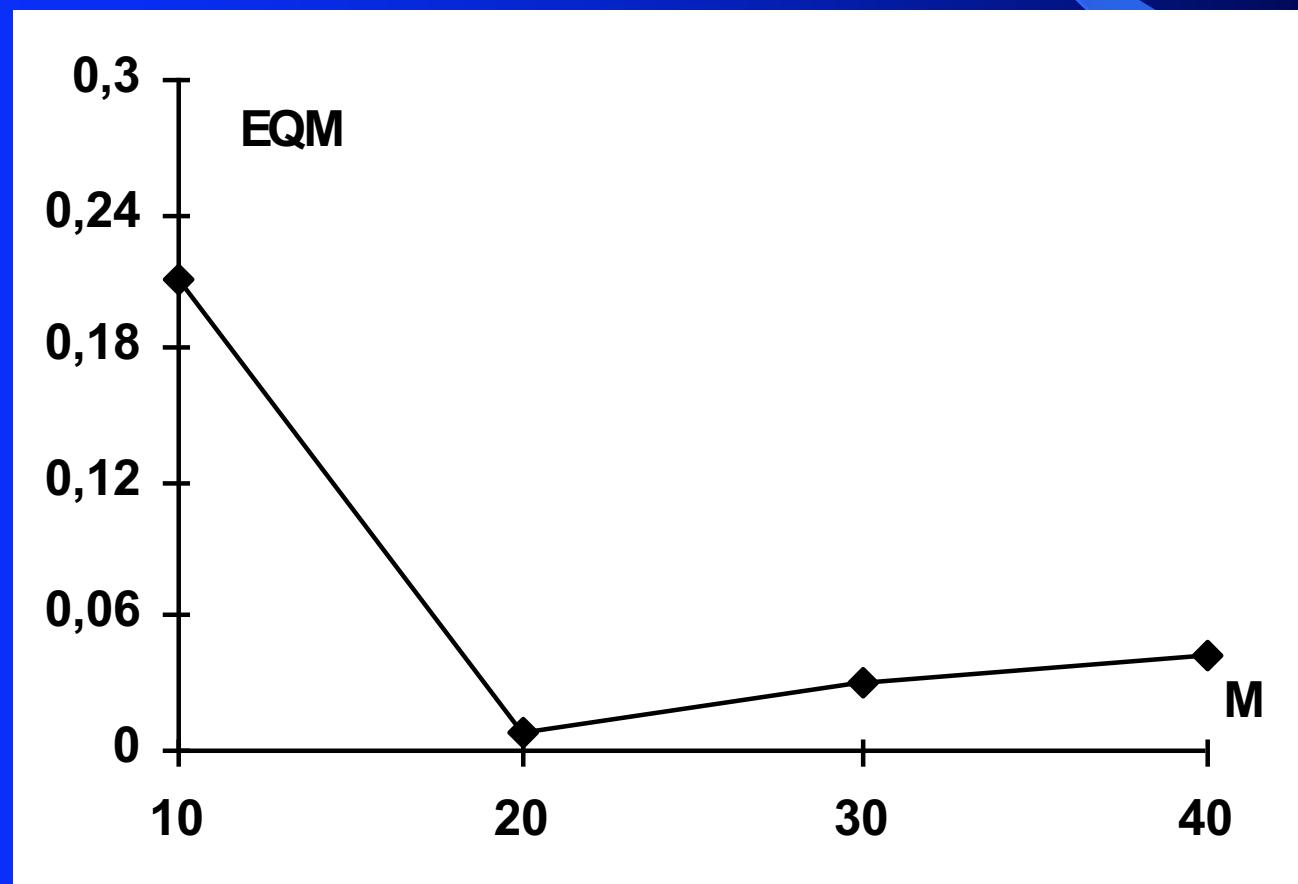


Figura 4 - Erro quadrático médio em função da época de treinamento para identificação usando NFN (●) e RNA (♦).

Influência do número de partições



Exemplo 2

$$y(k+1) = g[y(k), y(k-1)] + u(k)$$

$$g[y(k), y(k-1)] = \frac{y(k)y(k-1)[y(k)+2.5]}{1+y^2(k)+y^2(k-1)}$$

$$u(k) = \operatorname{sen}(2\pi k / 25)$$

$$\hat{y}(k+1) = \hat{g}[\hat{y}(k), \hat{y}(k-1)] + u(k)$$

Estrutura do NFN

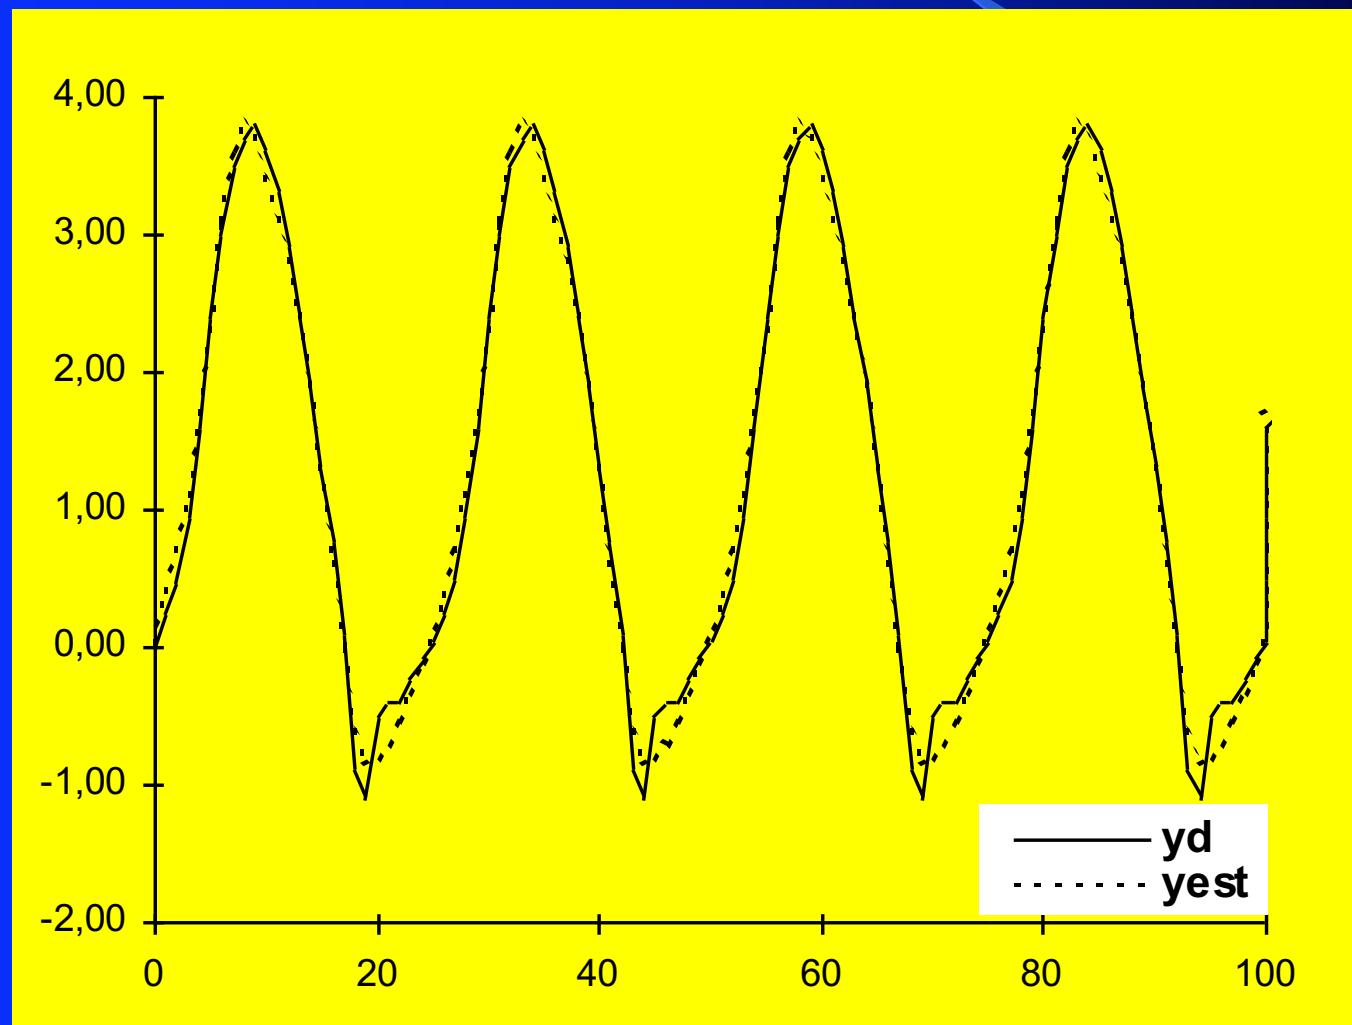
- Número de entradas: 2 ($y(k)$ e $y(k-1)$);
- Número de saídas: 1
- Número de partições nebulosas: 5 por entrada

Metodologia de treinamento

- padrões de treinamento: 10.000 com u aleatório no intervalo $[-1, +1]$
- padrões de validação:

$$u(k) = \text{sen}(2.\pi.k / 250)$$

Resultado da identificação



Exemplo 3

$$y(k+1) = g[y(k), y(k-1), y(k-2), u(k), u(k-1)]$$

$$g(x_1, x_2, x_3, x_4, x_5) = \frac{x_1 x_2 x_3 x_5 (x_3 - 1) + x_4}{1 + x_3^2 + x_4^2}$$

$$u(k) = \begin{cases} \text{sen}(2\pi k / 250), & \forall k \leq 500 \\ 0.8 \text{sen}(2\pi k / 250) + 0.2 \text{sen}(2\pi k / 25), & \forall k > 500 \end{cases}$$

$$\hat{y}(k+1) = \hat{g}[\hat{y}(k), \hat{y}(k-1), \hat{y}(k-2), u(k), u(k-1)]$$

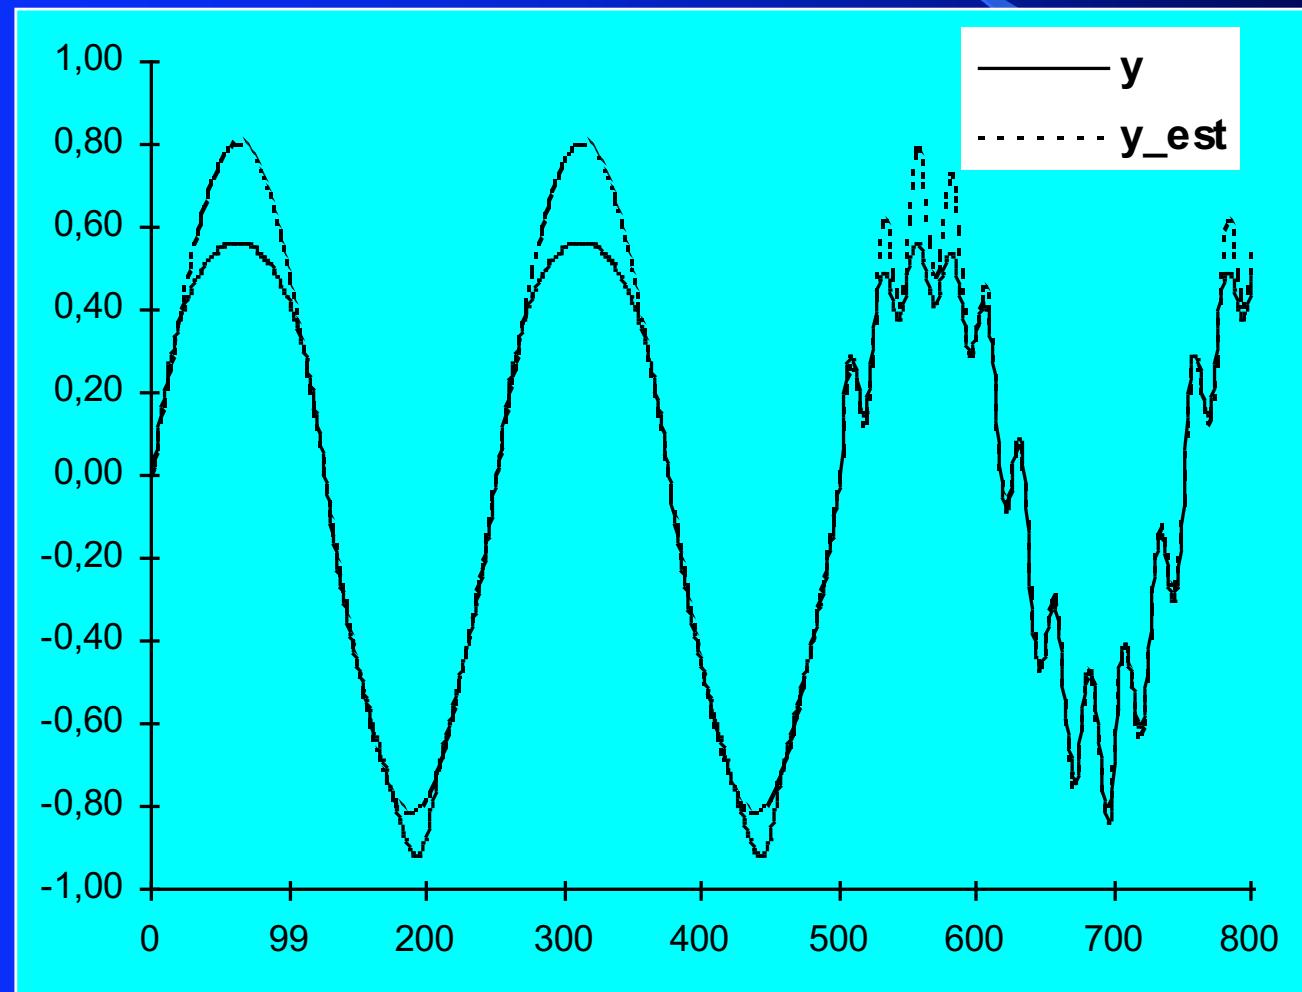
Estrutura do NFN

- Número de entradas: $y(k)$, $y(k-1)$, $y(k-2)$,
 $u(k)$ e $u(k-1)$
- Número de saídas: 1 ($y(k+1)$)
- Número de partições nebulosas: 3 para cada
entrada

Metodologia de treinamento 1

- Foram utilizados cinco mil padrões com $u(k)$ gerado aleatoriamente no intervalo $[-1,1]$;

Resultado para Metodologia 1



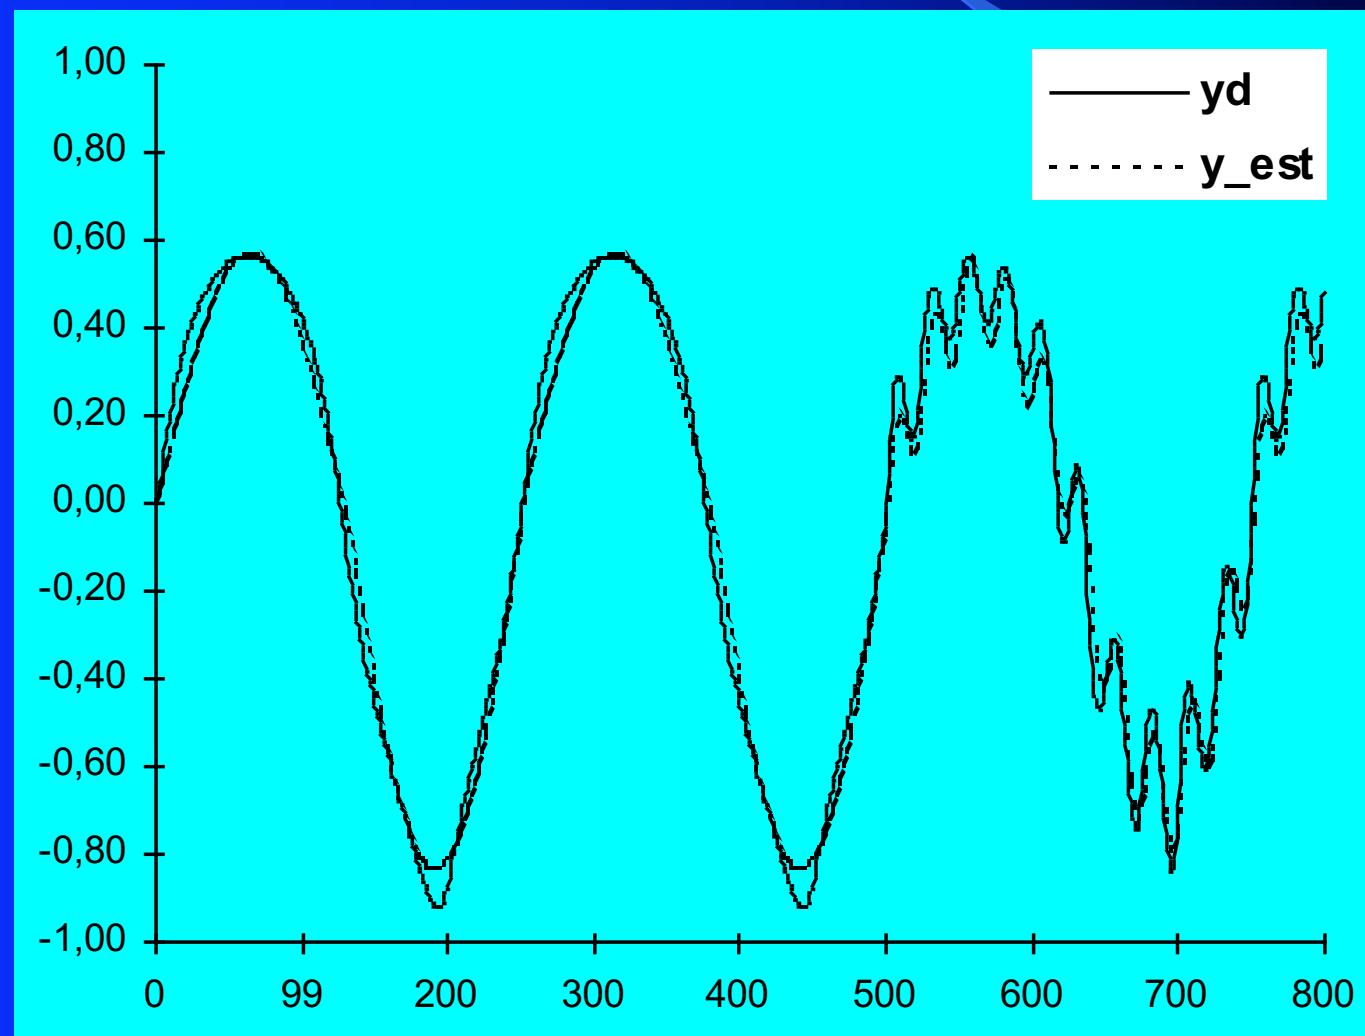
Metodologia de treinamento 2

- foram gerados duzentos e cinqüenta padrões com $u(k)$, determinado da seguinte forma:

$$u(k) = \text{sen}(2\pi k / 250) \text{ para } k = 1, 2, \dots, 250$$

- Estes duzentos e cinqüenta padrões foram repetidos 20 vezes.

Resultado para Metodologia 2



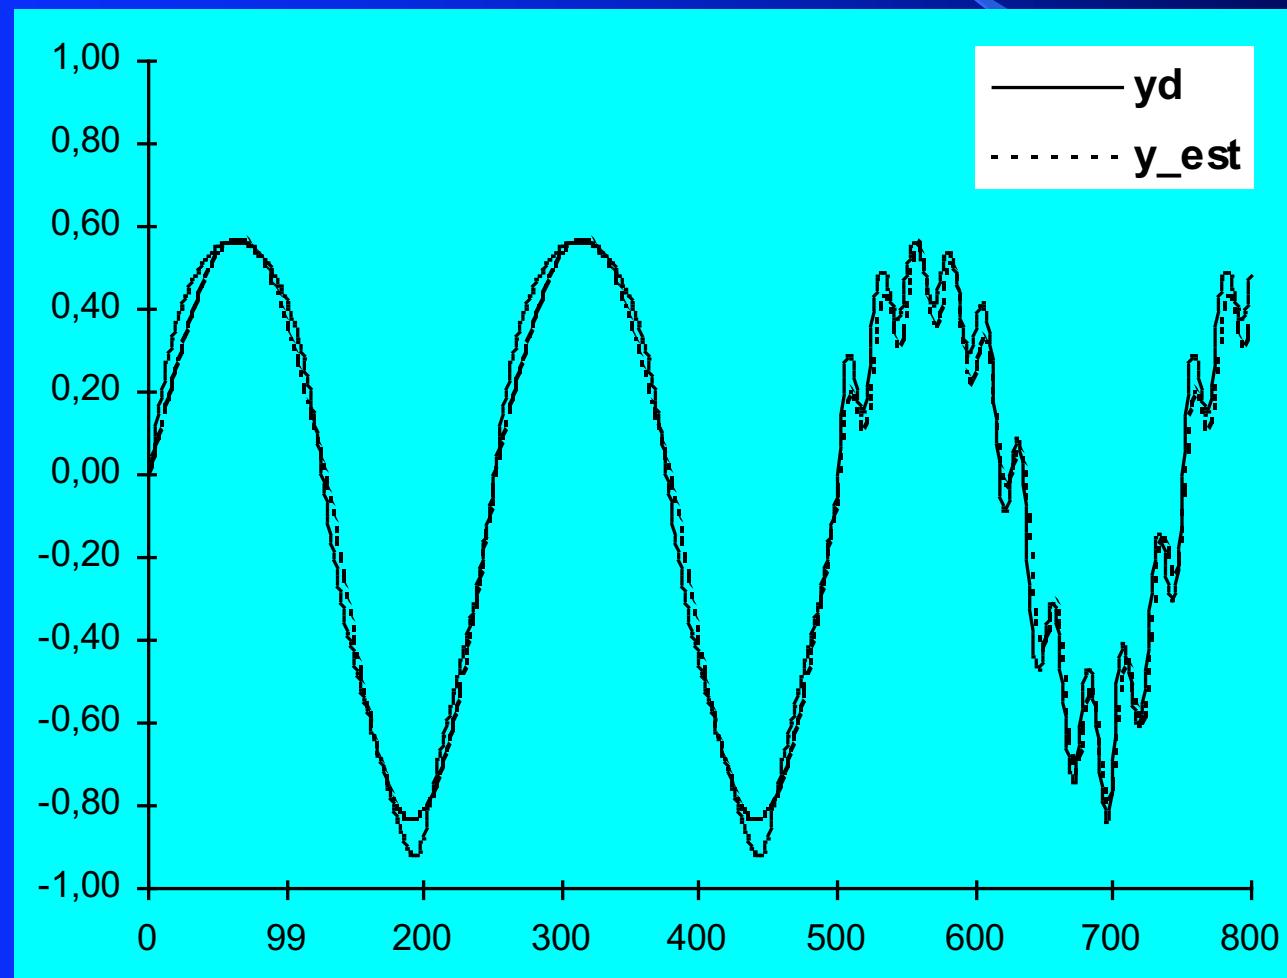
Metodologia de treinamento 2

- foram gerados cinco mil padrões com a entrada, $u(k)$, determinada da seguinte forma:

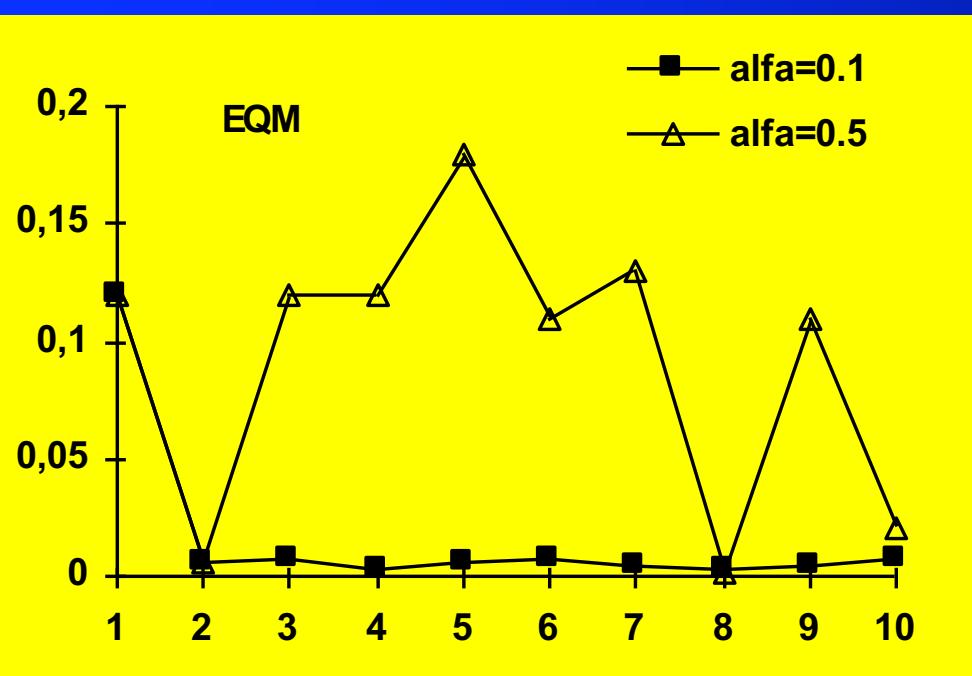
$$u(k) = a_1 \operatorname{sen}(2\pi k / b_1) + (1 - a_1), \text{ para } k = 1, 2, \dots, 5.000$$

- sendo a_1 , e b_1 números aleatórios com densidade de distribuição uniforme nos intervalos $[0, 1]$ e $[25, 250]$, respectivamente, alterados a cada 500 iterações.

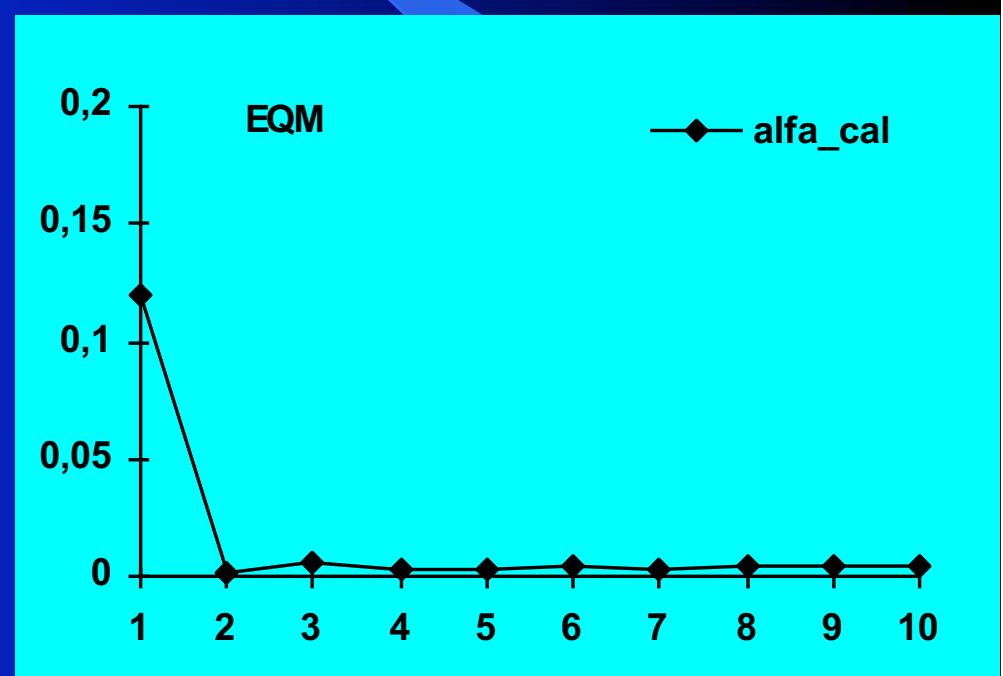
Resultado para Metodologia 3



Influência da Taxa de Aprendizado



Taxa de aprendizado fixa



Taxa de aprendizado ótima

COMPLEXIDADE COMPUTACIONAL

$$y_1 = \sum_{i=1}^n \mu_{ik_i}(x_i) \cdot w_{ik_il} + \mu_{ik_i+1}(x_i) \cdot w_{i(k_i+1)l}$$

NFN

$$Y = \Gamma[W^3 \Gamma[W^2 \Gamma[W^1 X]]]$$

RNA

COMPLEXIDADE COMPUTACIONAL

Tabela 1 – Comparação entre o NFN e a RNA

Estrutura	Operações de X	Operações de + e/ou -	cálculos de funções
RNA [n,p,q,m]	$n.p + p.q + q.m$	$n.p + p.q + q.m$	$p+q+m$ <i>(função sigmóide)</i>
NFN [n,p,m]	$2.n.m$	$n.m + n$	n <i>(função linear)</i>

Comparação entre o NFN e a RNA

Estrutura	Operações X	Operações +/-	Cálculo de Funções
RNA [2,10,20,1]	250	250	31 sigmóides
NFN [2,5,1]	10	20	2 funções lineares

Conclusões

- NFN é uma opção atraente em aplicações em tempo real e em treinamento *on-line*;
- **Alerta:** é possível utilizar estruturas simples, comparadas com RNA multcamadas, para identificar sistemas dinâmicos.

Algoritmo Neo-Fuzzy-Neuron (Generalização)

$$f_{li}(x_i) = \mu_{ik_i}(x_i) \cdot w_{ik_i} l + \mu_{i(k_i+1)}(x_i) \cdot w_{i(k_i+1)} l$$

$$y_l = \sum_{i=1}^n y_{li}(x_i) = \sum_{i=1}^n f_{li}(x_i) = f_{l1}(x_1) + f_{l2}(x_2) + \dots + f_{ln}(x_n)$$

$$\mathcal{E}_{lt} = \frac{1}{2} (y_{lt} - y_{lt}^d)^2 = \mathcal{E}_t(W_{ijl}), l=1, \dots, m$$

